

MODELAGEM DE PD — METODOLOGIA E VALIDAÇÃO

# Home Credit Default Risk

*Benchmark XGBoost e um scorecard de regressão logística WoE/IV totalmente auditável*

Aprofundamento técnico: engenharia de variáveis, seleção de variáveis, diagnóstico de multicolinearidade e protocolo de validação

## Base de dados, decisão de escopo e metodologia de avaliação

**307.511**

clientes (application\_train  
+ bureau.csv agregado)

**8,07%**

taxa histórica de  
inadimplência

**156**

colunas após o merge  
(154 variáveis candidatas)

**80/20**

split estratificado de  
treino/validação, seed fixa

### DECISÃO DE ESCOPO

Esta fatia do pipeline está limitada, de forma proposital, a application\_train.csv mais o bureau.csv agregado, não ao esquema relacional completo (previous\_application, POS\_CASH\_balance, credit\_card\_balance, installments\_payments). O objetivo foi validar um pipeline completo, de ponta a ponta, antes de escalar a complexidade dos dados, um sequenciamento deliberado no estilo MVP, não uma lacuna de escopo.

### METODOLOGIA DE VALIDAÇÃO

- XGBoost: 5-fold estratificado para a estimativa de performance, além de um split fixo de 80/20 para os artefatos de SHAP e curva de ganho
- Scorecard: tabelas de WoE e limites de bin calculados estritamente no split de treino, aplicados (nunca recalculados) na validação
- Curvas de ganho usam previsões out-of-fold (XGBoost, base inteira) ou validação separada (scorecard); as duas não estão na mesma população, ressalva explícita sempre que comparadas

# Agregação coluna a coluna do bureau.csv

bureau.csv (1.716.428 linhas, 17 colunas, 5,61 linhas/cliente) agregado ao nível de SK\_ID\_CURR usando um critério explícito por coluna, não média/soma genérica:

| Critério                   | Aplicado a                                                             | Racional                                                     |
|----------------------------|------------------------------------------------------------------------|--------------------------------------------------------------|
| soma                       | AMT_CREDIT_SUM, AMT_CREDIT_SUM_DEBT, AMT_CREDIT_SUM_LIMIT, AMT_ANNUITY | Exposição total é aditiva entre créditos                     |
| média                      | DAYS_CREDIT, CREDIT_DAY_OVERDUE, campos AMT_*                          | Perfil típico por crédito, normalizado pela contagem         |
| máximo                     | CREDIT_DAY_OVERDUE, AMT_CREDIT_MAX_OVERDUE, DAYS_CREDIT_UPDATE         | Sinal de pior caso que uma média diluiria                    |
| contagem / crosstab        | CREDIT_ACTIVE (4 categorias)                                           | Baixa cardinalidade, equivalente a one-hot via contagem      |
| nunique + contagem da moda | CREDIT_TYPE (15 categorias)                                            | Sinais de diversificação e concentração                      |
| excluída                   | CREDIT_CURRENCY                                                        | 99,92% concentrada em uma categoria, sem poder discriminante |

Resultado: 29 variáveis, bureau\_agg (305.811 clientes). Mesclado ao application\_train via SK\_ID\_CURR (left join): 44.020 clientes (14,3%) não têm histórico de bureau, um padrão MNAR consistente com os achados prévios da EDA, não um defeito de merge.

# Hiperparâmetros e validação estratificada em 5 folds

HIPERPARÂMETROS

|                    |                                        |
|--------------------|----------------------------------------|
| n_estimators       | 200                                    |
| max_depth          | 4                                      |
| learning_rate      | 0,05                                   |
| scale_pos_weight   | 11,39 (razão de classes do treino)     |
| tree_method        | hist                                   |
| enable_categorical | True (dtype category nativo do pandas) |

Nenhum tuning realizado nesta etapa; hiperparâmetros próximos do padrão usados como referência.

5-FOLD ESTRATIFICADO (154 VARIÁVEIS)

| Fold       | AUC              |
|------------|------------------|
| 1          | 0,7558           |
| 2          | 0,7640           |
| 3          | 0,7570           |
| 4          | 0,7628           |
| 5          | 0,7544           |
| Média (dp) | 0,7588 (±0,0039) |

HOLDOUT

0,7614

split único 80/20, dentro da faixa dos folds

O AUC do holdout (0,7614) cai dentro da faixa dos folds (0,7544–0,7640), confirmando que não é um artefato de split favorável. O desvio-padrão (0,0039) é pequeno em relação à média, indicando generalização estável.

## Diagnóstico de redundância na variante XGBoost de 15 variáveis

Top 15 selecionadas por importância nativa do modelo baseline treinado só no treino (evitando viés de seleção baseado em validação). Duas suspeitas de redundância foram testadas empiricamente, não assumidas só pela correlação:

### CONFIRMADA: DAYS\_EMPLOYED removida

DAYS\_EMPLOYED e YEARS\_EMPLOYED são uma transformação linear determinística uma da outra ( $YEARS = -DAYS/365$ ). As duas apareciam no top-15 ingênuo.

**AUC médio k-fold: 0,7514 → 0,7525**

Remover a duplicata exata melhorou o AUC (AMT\_CREDIT foi promovida ao conjunto), confirmando perda zero de informação.

### TESTADA E REVERTIDA: AMT\_GOODS\_PRICE mantida

AMT\_GOODS\_PRICE correlaciona 0,99 com AMT\_CREDIT, mas não é uma transformação determinística (entrada, financiamento parcial causam divergência).

**AUC médio k-fold: 0,7525 → 0,7499 (removida)**


A remoção prejudicou o AUC de forma mensurável: correlação alta sem relação funcional exata ainda carregava sinal marginal. As duas variáveis foram mantidas.

**Princípio: correlação é motivo para testar a remoção, não uma regra para remover automaticamente. Final: 15 variáveis, AUC médio k-fold 0,7525, AUC holdout 0,7538.**

# SHAP (agregado)

## PRINCIPAIS FATORES

- EXT\_SOURCE\_3, EXT\_SOURCE\_2, EXT\_SOURCE\_1: dominantes, valor alto empurra a previsão para menos risco
- AMT\_GOODS\_PRICE, AMT\_CREDIT, AMT\_ANNUITY: valores mais altos associam a menos risco
- Variáveis categóricas (NAME\_EDUCATION\_TYPE, CODE\_GENDER, NAME\_CONTRACT\_TYPE) não mostram gradiente de cor: efeito real existe, mas sem escala contínua de "mais ou menos"
- Limitação: explica o modelo em agregado, não a pontuação de nenhum solicitante individual



## Por que WoE/IV, e as fórmulas por trás

### RACIONAL

- XGBoost captura não linearidade nativamente (splits de árvore); o WoE existe justamente para dar essa mesma capacidade a um modelo linear
- A estrutura aditiva da regressão logística (intercepto +  $\sum$  coeficiente  $\times$  WoE) é exatamente o que uma tabela de pontos exige
- Expectativa regulatória em risco de crédito: uma explicação auditável, coeficiente a coeficiente, para cada decisão

$$\text{WoE} = \ln( \% \text{bons} / \% \text{maus} )$$

$$\text{IV} = \sum ( \% \text{bons} - \% \text{maus} ) \times \text{WoE}$$

*%bons/%maus calculado com suavização aditiva (Laplace),  $\alpha = 0,5$ , para evitar  $\ln(x/0)$  quando um bin tem zero casos maus.*

### LIMIARES DE IV (SIDDIQI)

| Faixa de IV | Força                         |
|-------------|-------------------------------|
| < 0,02      | Sem discriminação             |
| 0,02 – 0,10 | Fraca                         |
| 0,10 – 0,30 | Média                         |
| 0,30 – 0,50 | Forte                         |
| > 0,50      | Suspeita (possível vazamento) |

# Varredura completa de IV, deduplicação por conceito, correção de instabilidade

155 variáveis candidatas testadas por IV. A deduplicação por conceito (agrupamento via regex das variantes \_AVG/\_MODE/\_MEDI e dos pares DAYS\_X/YEARS\_X, mantendo a de maior IV por grupo) reduziu para 121.

## CORREÇÕES DE INSTABILIDADE APLICADAS AO BUFFER TOP-40 (11 VARIÁVEIS SINALIZADAS)

| Grupo                          | Variáveis                                                                                     | Correção                                                                                                  |
|--------------------------------|-----------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| 1 — bin de Missing esparso     | EXT_SOURCE_2, AMT_GOODS_PRICE, DAYS_LAST_PHONE_CHANGE                                         | Fundido no bin numérico mais próximo por WoE                                                              |
| 2 — categoria rara única       | CODE_GENDER (XNA, 4 registros)                                                                | Mantida como resíduo documentado; volume insuficiente para qualquer critério de fusão                     |
| 3 — muitas categorias pequenas | OCCUPATION_TYPE, ORGANIZATION_TYPE, NAME_INCOME_TYPE, WALLSMATERIAL_MODE                      | Agrupadas em 'Other_grouped', com fusão em cascata para a categoria grande mais próxima se ainda instável |
| 4 — valor Zero dominante       | BUREAU_AMT_CREDIT_SUM_DEBT_SUM (29,2% zero),<br>BUREAU_AMT_CREDIT_SUM_LIMIT_MEAN (79,9% zero) | Zero isolado como bin explícito próprio                                                                   |

AMT\_GOODS\_PRICE exigiu uma resolução dedicada: o WoE ingênuo de 10 bins não era monotônico (não é artefato de amostra pequena, todos os bins > 18.900 registros). Um binning mais fino (20 bins) elevou o IV de 0,0919 para 0,1025; fusão cirúrgica iterativa (pares de menor diferença de WoE primeiro) reduziu para 12 bins com IV 0,1006, validada como estável em 5 folds (desvio-padrão de WoE entre 0,005–0,037 por bin). Posteriormente excluída do conjunto final por motivos de comunicação de negócio, não estatísticos, e substituída por ELEVATORS\_AVG.



# Redução baseada em correlação: 30 → 22 variáveis

A checagem de sinal na regressão logística inicial de 30 variáveis sinalizou 8 de 30 coeficientes com sinal inesperado (convenção do WoE: o coeficiente deveria ser negativo, já que WoE mais alto = bin mais seguro = menor log-odds de default). Uma varredura sistemática de correlação par a par ( $|r| \geq 0,7$ ) identificou dois clusters redundantes:

| Cluster                    | Variáveis (maior $ r $ )                                                                             | Mantida (maior IV)           |
|----------------------------|------------------------------------------------------------------------------------------------------|------------------------------|
| Atributos do imóvel        | TOTALAREA_MODE, LIVINGAREA_AVG, FLOORSMAX_AVG, ELEVATORS_AVG ( $r = 0,84-0,94$ )                     | FLOORSMAX_AVG                |
| Datas de crédito em bureau | BUREAU_DAYS_CREDIT_MEAN/MIN, _UPDATE_MEAN, _ENDDATE_MEAN, DAYS_ENDDATE_FACT_MEAN ( $r = 0,71-0,89$ ) | BUREAU_DAYS_CREDIT_MEAN      |
| Valores em bureau          | BUREAU_AMT_CREDIT_SUM_DEBT_MEAN/SUM ( $r = 0,85$ ); LIMIT_MEAN/SUM ( $r = 0,81$ )                    | A variante _MEAN de cada par |

Regra: em cada par correlacionado, manter a variável de maior IV, descartar a outra. Resultado: 8 variáveis removidas, 22 restantes.

0,7417

AUC antes

0,7408

AUC depois

8 → 4

Inconsistências de sinal

# O agrupamento por tipo de informação do Siddiqi aplicado aos 4 sinais restantes

4 variáveis ainda mostravam sinal de coeficiente inesperado após a poda por correlação. O método de regressão agrupada do Siddiqi (Cap. 10, Exhibit 10.14) avalia variáveis por grupo de tipo de informação antes de combiná-las, entrando deliberadamente com o grupo dominante por último:

**GRUPOS (NA ORDEM DE ENTRADA):** pessoal/demográfico (10) → crédito atual (2) → histórico de bureau (7) → score externo (3, entra por último)

| Passo cumulativo   | AGE_YEARS         | BUREAU_CREDIT_ACTIVE_CLOSED_COUNT |
|--------------------|-------------------|-----------------------------------|
| + demográfico      | -0,4663 (correto) | —                                 |
| + crédito atual    | -0,4323 (correto) | —                                 |
| + histórico bureau | -0,3068 (correto) | +0,4029 (inesperado)              |
| + score externo    | +0,1241 (inverte) | +0,0247 (n.s., p = 0,63)          |

## ABLAÇÃO CONFIRMA A DOMINÂNCIA

Modelo reajustado sem nenhuma variável EXT\_SOURCE: AGE\_YEARS volta a -0,3202 (sinal correto). O AUC cai para 0,6845 (de 0,7408), quantificando quanto poder preditivo o score externo sozinho contribui.

A inversão de sinal de AGE\_YEARS é explicada pela dominância do EXT\_SOURCE. BUREAU\_CREDIT\_ACTIVE\_CLOSED\_COUNT não é, ela já é inesperada antes mesmo do EXT\_SOURCE entrar, e se torna estatisticamente não significativa (p = 0,63) no modelo completo. Esse diagnóstico explica 1 dos 4 sinais restantes; as outras 3 (incluindo BUREAU\_CREDIT\_ACTIVE\_CLOSED\_COUNT) exigiram uma abordagem diferente, tratada a seguir.

# De 22 para 17 variáveis

Correlação e VIF descartaram multicolinearidade como causa dos sinais restantes (BUREAU\_DAYS\_CREDIT\_UPDATE\_MAX, NAME\_INCOME\_TYPE\_BINNED, BUREAU\_CREDIT\_ACTIVE\_CLOSED\_COUNT): todos os valores de VIF no cluster de bureau ficaram abaixo de 2,2, bem abaixo do limiar de preocupação convencional (5). Sem causa estatística isolável, o critério de decisão restante foi empírico: remover a variável reduz o AUC de forma mensurável?

| Variável do grupo bureau          | Máx.  r  par a par | VIF  |
|-----------------------------------|--------------------|------|
| BUREAU_DAYS_CREDIT_ENDDATE_MEAN   | 0,63               | 2,14 |
| BUREAU_DAYS_CREDIT_UPDATE_MAX     | 0,60               | 2,02 |
| BUREAU_DAYS_CREDIT_MEAN           | 0,63               | 1,96 |
| BUREAU_CREDIT_ACTIVE_ACTIVE_COUNT | 0,59               | 1,82 |
| BUREAU_AMT_CREDIT_SUM_DEBT_MEAN   | 0,60               | 1,76 |
| BUREAU_CREDIT_ACTIVE_CLOSED_COUNT | 0,53               | 1,50 |
| BUREAU_AMT_CREDIT_SUM_LIMIT_MEAN  | 0,36               | 1,20 |

## ELIMINAÇÃO RETROATIVA, PASSO A PASSO

| Passo                                                                                 | n var. | AUC    |
|---------------------------------------------------------------------------------------|--------|--------|
| Poda por correlação                                                                   | 22     | 0,7408 |
| – BUREAU_CREDIT_ACTIVE_CLOSED_COUNT (p = 0,63, teste de significância formal)         | 21     | 0,7408 |
| – AGE_YEARS, NAME_INCOME_TYPE_BINNED, BUREAU_DAYS_CREDIT_UPDATE_MAX (testadas juntas) | 18     | 0,7406 |
| – BUREAU_DAYS_CREDIT_ENDDATE_MEAN (coef ≈ 0,011)                                      | 17     | 0,7406 |

*O VIF descarta a multicolinearidade combinada como causa; ele não identifica qual é a causa.*

Cada passo acima é o mesmo critério aplicado duas vezes, uma formalmente (p-valor, um teste estatístico de se um coeficiente poderia ser zero dadas as outras variáveis), outra por ablação direta (remover e remedir o AUC). Custo total: 0,0011 de AUC (0,7417 → 0,7406) para eliminar toda inconsistência de sinal em 13 variáveis removidas.

# Regressão logística de 17 variáveis, todos os coeficientes com sinal consistente

| Variável                   | Coeficiente |
|----------------------------|-------------|
| EXT_SOURCE_2               | -0,7628     |
| EXT_SOURCE_3               | -0,7553     |
| NAME_EDUCATION_TYPE_BINNED | -0,5863     |
| EXT_SOURCE_1               | -0,5264     |
| AMT_CREDIT                 | -0,5188     |
| CODE_GENDER                | -0,4689     |
| YEARS_EMPLOYED             | -0,3594     |
| ORGANIZATION_TYPE_BINNED   | -0,3495     |

| Variável                          | Coeficiente |
|-----------------------------------|-------------|
| FLOORSMAX_AVG                     | -0,3235     |
| BUREAU_CREDIT_ACTIVE_ACTIVE_COUNT | -0,2549     |
| BUREAU_AMT_CREDIT_SUM_LIMIT_MEAN  | -0,2411     |
| OCCUPATION_TYPE_BINNED            | -0,2383     |
| REGION_POPULATION_RELATIVE        | -0,2029     |
| DAYS_ID_PUBLISH                   | -0,1957     |
| BUREAU_AMT_CREDIT_SUM_DEBT_MEAN   | -0,1653     |
| DAYS_LAST_PHONE_CHANGE            | -0,1610     |
| BUREAU_DAYS_CREDIT_MEAN           | -0,0793     |

Os 17 coeficientes são negativos, consistentes com a convenção do WoE (WoE mais alto = bin mais seguro = menor log-odds de default). Sem exceções.

# Derivação de Factor/Offset e duas tentativas de calibração

**Score = Offset + Factor × ln(odds)**

**Factor = PDO / ln(2)**

**Offset = Score\_ref – Factor × ln(Odds\_ref)**

| Tentativa | Parâmetros                                                                                   | Resultado                                                                                                                |
|-----------|----------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| 1         | PDO=20, Score=600, Odds=50:1 (convenção de mercado)                                          | Faixa estreita demais (402–582); ponto de ancoragem (50:1) muito mais seguro que a odds real da base (11,4:1)            |
| 2         | PDO=20, Score=500, Odds=11,4:1 (implícita pelo bad rate)                                     | Média não bateu com 500 (439,6); class_weight='balanced' deslocou o intercepto do próprio modelo para longe da odds real |
| Final     | PDO=40, Score=500, Offset ancorado na média empírica de log-odds do próprio modelo no treino | Média 500,16, desvio-padrão 52,72, faixa 312–669 (validação)                                                             |

Lição principal: class\_weight='balanced' recalibra o intercepto do modelo para tratar as classes como igualmente ponderadas, então o log-odds médio previsto pela população deixa de bater diretamente com o bad rate real de 8,07%. O offset precisa se ancorar na média empírica do próprio modelo, não em um valor teórico implícito do bad rate.

Contribuição em pontos por bin: base\_points\_per\_characteristic + (–Factor × coeficiente × WoE), com o termo constante (Offset – Factor × intercepto) distribuído igualmente entre as 17 características. Validado de forma aditiva: a soma dos pontos reproduz o score direto do modelo, dentro do arredondamento.

## AUC, KS, Gini, e controles de vazamento

AUC

0,7406

KS

0,3621

Gini

0,4812

Gini =  $2 \times \text{AUC} - 1$  (0,4812, confere). KS na faixa "razoável a boa" pelos limiares usuais de mercado (30–40).

### CONTROLES DE VAZAMENTO

- Tabelas de WoE e limites de bin congelados estritamente no split de treino; os dados de validação são só consultados, nunca usados para recalculando bins ou categorias
- Bins numéricos comparados por posição (pd.cut com limites fixos, labels=False)
- O agrupamento de categorias raras é congelado como um dicionário explícito de categoria bruta para bucket; categorias nunca vistas na hora de pontuar caem em 'Other\_grouped' ou 'Missing', nunca um bucket novo

## Redução absoluta e relativa da taxa de inadimplência

| Rejeitados | XGBoost (p.p.) | Scorecard (p.p.) | Scorecard (% relativo) |
|------------|----------------|------------------|------------------------|
| 5%         | 1,33           | 1,19             | 14,7%                  |
| 10%        | 2,10           | 1,95             | 24,2%                  |
| 15%        | 2,73           | 2,45             | 30,4%                  |
| 20%        | 3,24           | 2,93             | 36,3%                  |
| 25%        | 3,68           | 3,38             | 41,9%                  |
| 30%        | 4,04           | 3,76             | 46,6%                  |

**~90–93%**

do ganho de negócio do baseline XGBoost é retido pelo scorecard de 17 variáveis, em todos os limiares de rejeição testados